

LAB02

Danillo dos Santos Lemes (174608)

```
library(readr)
library(dplyr)
```

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

`filter`, `lag`

Os seguintes objetos são mascarados por 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

```
library(devtools)
```

Warning: pacote 'devtools' foi compilado no R versão 4.6.1

Carregando pacotes exigidos: usethis

Warning: pacote 'usethis' foi compilado no R versão 4.6.1

```
library(ggcal)
library(ggplot2)
```

1) Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

R: As estatísticas suficientes para a determinação percentual é a contagem de cada grupo, que seria o total de voos e a soma dos voos atrasados em mais de 10 minutos, logo o percentual de atraso é obtido por meio da razão entre voos atrasados e o total.

2)

```
getStats <- function(input, pos) {  
  input %>%  
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%  
    filter(!is.na(ARRIVAL_DELAY),  
           !is.na(DAY),  
           !is.na(MONTH),  
           !is.na(AIRLINE)) %>%  
  group_by(DAY, MONTH, AIRLINE) %>%  
    summarise(  
      n_total = n(),  
      n_atrasado = sum(ARRIVAL_DELAY > 10),  
      .groups = "drop"  
    )  
}
```

3)

```
stats_acumuladas <- read_csv_chunked(  
  file      = "flights.csv.zip",  
  callback  = DataFrameCallback$new(getStats),  
  chunk_size = 100000,  
  col_types = cols_only(  
    MONTH = col_integer(),  
    DAY = col_integer(),  
    AIRLINE = col_character(),  
    ARRIVAL_DELAY = col_double()  
  ),  
)
```

4)

```
computeStats <- function(data_stats) {  
  data_stats %>%  
    group_by(AIRLINE, MONTH, DAY) %>%  
    summarise(  
      total_atrasados = sum(n_atrasado),  
    )  
}
```

```

    total_voos      = sum(n_total),
    .groups         = "drop"
  ) %>%
  transmute(
    Cia = AIRLINE,
    Data = as.Date(sprintf("2015-%02d-%02d", MONTH, DAY)),
    Perc = total_atrasados / total_voos
  )
}

statos_finais <- computeStats(stats_acumuladas)

```

5)

```

pal <- scale_fill_gradient(
  low = "#4575b4",
  high = "#d73027"
)

baseCalendario <- function(stats, cia) {
  sub_stats <- stats %>%
    filter(Cia == cia)


  ggcal(sub_stats$Data, sub_stats$Perc)
}

cAA <- baseCalendario(statos_finais, "AA")
cDL <- baseCalendario(statos_finais, "DL")
cUA <- baseCalendario(statos_finais, "UA")
cUS <- baseCalendario(statos_finais, "US")

cAA + pal + ggtitle("Percentual de Atrasos na Chegada (2015) - American Airlines (AA)")


```

Percentual de Atrasos na Chegada (2015) – American Airlines (AA)




```
cDL + pal + ggtitle("Percentual de Atrasos na Chegada (2015) – Delta Air Lines (DL)")
```

Percentual de Atrasos na Chegada (2015) – Delta Air Lines (DL)




```
cUA + pal + ggtitle("Percentual de Atrasos na Chegada (2015) - United Airlines (UA)")
```

Percentual de Atrasos na Chegada (2015) – United Airlines (UA)



```
cUS + pal + ggtitle("Percentual de Atrasos na Chegada (2015) - US Airways (US)")
```

Percentual de Atrasos na Chegada (2015) – US Airways (US)



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-24 21:39:41 -03"
```